

POLITECNICO DI BARI

DIPARTIMENTO DI INGEGNERIA ELETTRICA E DELL'INFORMAZIONE

CORSO DI LAUREA MAGISTRALE IN

ARTIFICIAL INTELLIGENCE

REPORT DI PROGETTO IN

DEEP LEARNING

TINY TEXT-CONDITIONED AVATAR DIFFUSION

Generazione Di Avatar Cartoon Condizionata Da Testo

Prof. Vito Walter Anelli

Studenti
Domenico D'Ambrosio
Mauro Pasquale

ANNO ACCADEMICO 2026/2027

Sommario

Sintesi 3
1) Obiettivo e protocollo sperimentale 3
2) Dati, caption e preprocessing 4
Caption e tokenizzazione 5
3) Modello e training 6
Architettura 6
Validazione prima del training completo 8
4) Risultati quantitativi 8
Costo computazionale 9
5) Valutazione qualitativa e OOD 10
Confronto controllato con la baseline 10
Campioni composizionali OOD 11
6) Conditioning e diversity 13
Proxy nearest-neighbor 13
Diversity a prompt fisso 14
7) Discussione e limiti 16
Miglioramenti futuri 16
8) Conclusioni 17

Sintesi

Il progetto implementa e addestra da zero un modello **DDPM** nello spazio dei pixel per generare avatar cartoon condizionati da descrizioni testuali strutturate. La pipeline comprende il preprocessing dei dati con controlli di integrità, uno split composizionale out-of-distribution (OOD), un tokenizer WordLevel, un encoder testuale Transformer e una U-Net multirisoluzione con blocchi residuali, embedding temporali e cross-attention. Il protocollo sperimentale prevede un addestramento riproducibile, il confronto con una baseline non condizionata e una valutazione quantitativa e qualitativa dei risultati. A parità di protocollo di valutazione, il modello condizionato ottiene una loss di validazione e un Kernel Inception Distance (KID) inferiori rispetto alla baseline. L'analisi finale discute inoltre i limiti della proxy utilizzata per valutare la coerenza tra le immagini generate e gli attributi richiesti nelle descrizioni testuali.

1) Obiettivo e protocollo sperimentale

L'obiettivo è costruire un generatore text-conditioned in cui i componenti siano addestrati da zero, senza ricorrere a modelli generativi pre-addestrati. Durante l'addestramento il denoiser apprende a stimare il rumore aggiunto alle immagini; nel processo inverso tale rumore viene progressivamente rimosso per generare un avatar coerente con la descrizione testuale. Il confronto con una U-Net non condizionata, addestrata con lo stesso numero di step e le stesse principali impostazioni, consente di valutare il beneficio complessivo della configurazione condizionata dal testo. Non si tratta invece di uno studio di ablazione a parità esatta di parametri, poiché il modello condizionato comprende anche l'encoder testuale e i moduli di cross-attention.

Il protocollo sperimentale ha un ambito volutamente circoscritto e comprende la preparazione dei dati, la definizione degli split, l'implementazione del processo diffusivo e il confronto tra i due modelli. Le principali caratteristiche approfondite nelle sezioni successive sono:

- Dataset Google Cartoon Set 10k: 10.000 avatar RGB, ridimensionati durante la fase di pre-processing a 32 x 32 pixel [1].
- Split: train 7.884, validation 986, test ordinary 986 e test OOD 144.
- DDPM con 1.000 timestep, schedule lineare beta da 0.0001 a 0.02 ed epsilon prediction.
- Confronto interno coerente: conditional contro baseline unconditional.

Nel forward process, all'immagine originale viene aggiunto un rumore gaussiano secondo la distribuzione riportata di seguito, dove x_0 è l'immagine reale priva di rumore, x_t la sua versione rumorosa al timestep t e $\bar{a}_t$ il prodotto cumulativo della schedule.

$$q\,(x_t|\,x_0) = N(\sqrt{\bar{a}_t}x_0, (1-\bar{a}_t)\,\mathrm{I}\,)$$

Equazione 1. *Processo di forward diffusion.*

Il modello minimizza quindi l'errore quadratico fra il rumore noto ε e la sua stima $\hat{\varepsilon}_\theta$, condizionata anche dal contesto testuale c nel caso conditional.

$$L = E_{x_0,\varepsilon,t}[\ \|\varepsilon - \hat{\varepsilon}_\theta(x_t, t, c)\|_2^2]$$

Equazione 2. *Obiettivo di epsilon prediction.*

Il campionamento inverso, o reverse sampling, inizia da un'immagine costituita da rumore gaussiano e procede gradualmente a ritroso lungo i timestep della diffusione. A ogni passo, la U-Net analizza l'immagine rumorosa corrente e predice la componente di rumore ancora presente; questa previsione, insieme ai coefficienti fissati dalla noise schedule, permette di ricostruire una stima dell'immagine pulita. Per garantire coerenza con la normalizzazione adottata nel dataset, tale stima viene limitata all'intervallo [-1, 1] e utilizzata per determinare la distribuzione dello stato precedente, da cui viene campionata l'immagine al timestep successivo del processo inverso. La procedura viene ripetuta fino a ottenere il campione finale, mentre nell'ultimo passaggio non viene introdotta ulteriore componente casuale. Nel modello condizionato, inoltre, la rappresentazione del prompt testuale viene calcolata una sola volta prima dell'avvio del ciclo e poi riutilizzata dalla U-Net, tramite cross-attention, in tutti i passaggi di denoising.

2) Dati, caption e preprocessing

La preparazione dei dati prevede una serie di controlli volti a garantirne l'integrità e la coerenza. In particolare, la pipeline verifica la corrispondenza univoca tra ciascuna immagine PNG e il relativo file CSV contenente i metadati, l'unicità degli identificativi, il rispetto degli intervalli ammessi per gli attributi e l'assenza di valori mancanti. Le immagini vengono caricate soltanto al momento dell'utilizzo, secondo una modalità di caricamento lazy, e normalizzate nell'intervallo [-1, 1].

La scelta di ridimensionare le immagini a 32x32 pixel consente di contenere il costo computazionale e di studiare direttamente le fasi di diffusione diretta, denoising e campionamento inverso nello spazio dei pixel, senza ricorrere ad autoencoder latenti o modelli pre-addestrati. Questa risoluzione comporta, tuttavia, una minore capacità di rappresentare i dettagli più fini e può contribuire alla presenza di contorni poco definiti nei campioni generati.

Per valutare la generalizzazione composizionale, lo split out-of-distribution (OOD) è costituito esclusivamente dagli esempi che presentano contemporaneamente gli attributi face_shape = 3 e hair_color = 3. Una volta esclusi questi esempi, i dati rimanenti vengono suddivisi in training, validation e test ordinario nelle proporzioni dell'80%, 10% e 10%, mediante una stratificazione congiunta rispetto a hair_color e face_shape.

I due valori che definiscono la combinazione OOD rimangono presenti singolarmente nel training set, ma non compaiono mai insieme. L'audit dei dati verifica inoltre che tutti i valori previsti per ciascun attributo siano rappresentati nel training. Il test OOD valuta quindi la capacità del modello di ricombinare caratteristiche già osservate separatamente, anziché di gestire valori di attributo mai incontrati durante l'addestramento.

Caption e tokenizzazione

A partire dai metadati associati a ciascun avatar, il progetto costruisce una descrizione testuale deterministica, o caption, che rappresenta gli attributi visivi dell'immagine. Ogni descrizione segue sempre la stessa struttura e combina otto informazioni: forma e colore del viso, acconciatura e colore dei capelli, colore degli occhi, lunghezza del mento, presenza di peli facciali e occhiali. Di conseguenza, una medesima combinazione di attributi produce invariabilmente la stessa caption, rendendo il collegamento tra metadati e condizionamento testuale trasparente e riproducibile.

Le caption vengono poi trasformate in sequenze di token mediante un tokenizer di tipo WordLevel, addestrato esclusivamente sulle descrizioni appartenenti allo split di training. Il vocabolario risultante contiene 132 token, compresi i simboli speciali [SOS], [EOS], [PAD] e [UNK]; dopo l'aggiunta dei token di inizio e fine sequenza, padding e troncamento rendono ogni input lungo 44 token. Questa scelta evita che le caption dei dati di validazione e test contribuiscano alla definizione del vocabolario e assicura una rappresentazione testuale uniforme per il batching del modello.

Nella formulazione delle caption, ciascun attributo è espresso attraverso il termine variant seguito da un identificatore numerico. Tali numeri non rappresentano grandezze ordinate, ma semplici etichette discrete che distinguono le diverse categorie disponibili per un attributo. Il testo non viene quindi impiegato per valutare capacità di comprensione del linguaggio naturale libero: costituisce invece un'interfaccia controllata attraverso cui analizzare se il modello riesca a seguire gli attributi richiesti e a ricombinarli durante la generazione.

La tabella seguente riporta la corrispondenza tra gli attributi presenti nei metadati e le espressioni testuali utilizzate per descriverli. Le espressioni sono mostrate separatamente per maggiore leggibilità, mentre nell'input effettivamente fornito al modello vengono concatenate in un'unica caption.

Metadata	Caption
• face_shape=4 • face_color=1 • hair=101 • hair_color=6 • eye_color=2 • chin_length=1 • facial_hair=2 • glasses=11	• a cartoon avatar with face shape variant 4 • face color variant 1 • hairstyle variant 101 • hair color variant 6 • eye color variant 2 • chin length variant 1 • facial hair variant 2 • glasses variant 11

3) Modello e training

Architettura

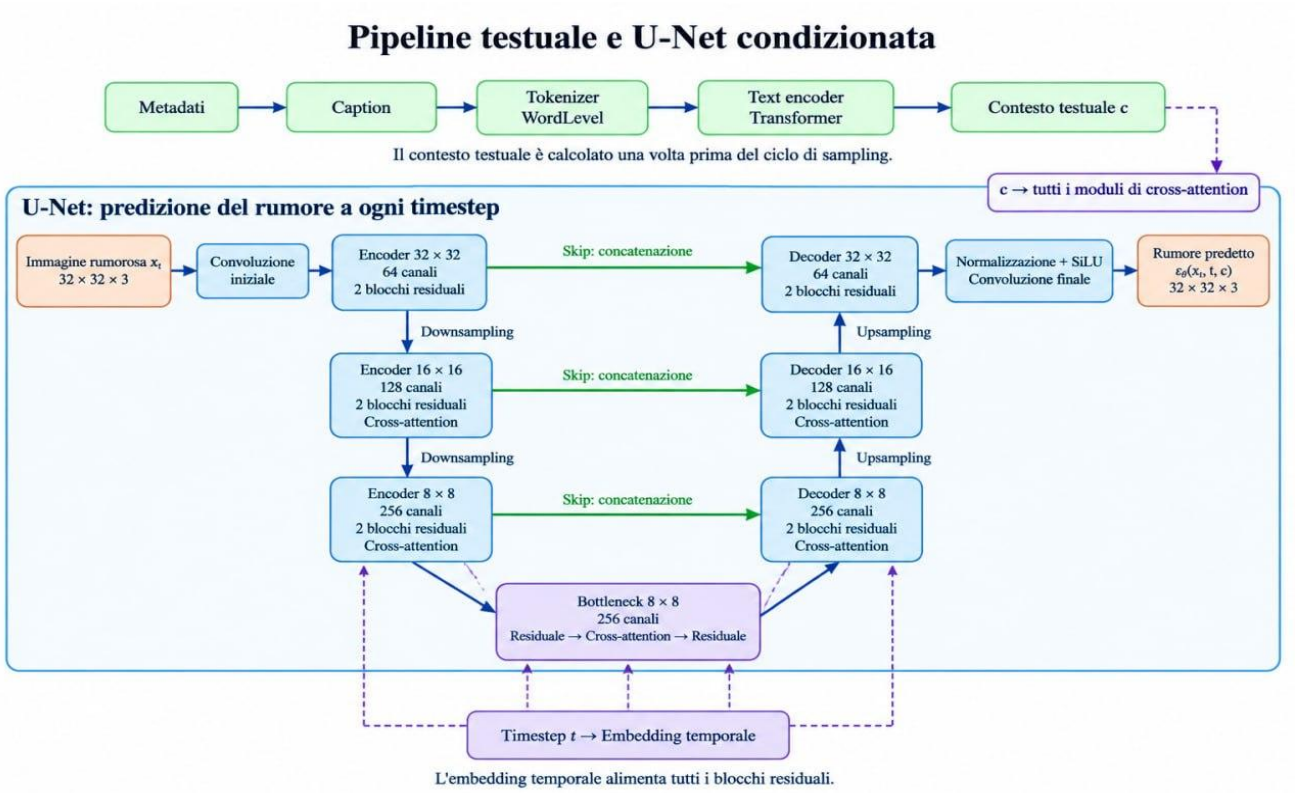
Il modello condizionato combina un text encoder Transformer e un denoiser U-Net, entrambi addestrati da zero. Il text encoder adotta un'architettura pre-norm con positional encoding sinusoidale, dimensione nascosta pari a 128 e 4 layer Transformer, ciascuno con quattro teste di attenzione. Il suo compito è trasformare la sequenza di token della caption in una rappresentazione contestuale token-level, utilizzata successivamente dal denoiser.

La U-Net riceve l'immagine rumorosa e opera su tre risoluzioni spaziali: (32 × 32), (16 × 16) e (8 × 8) pixel, con rispettivamente 64, 128 e 256 canali. In ogni livello dell'encoder e del decoder sono presenti due blocchi residuali, condizionati dall'embedding temporale del timestep corrente. L'embedding temporale è prima costruito con una codifica sinusoidale e poi trasformato da un piccolo MLP.

Il conditioning testuale viene introdotto tramite moduli di cross-attention 2D ai livelli (16 × 16) e (8 × 8), sia nel percorso di encoder sia nel decoder, oltre che nel bottleneck. In questo modo, le feature spaziali dell'immagine agiscono come query e attribuiscono pesi diversi ai token della caption, selezionando le informazioni testuali più rilevanti per la regione e per lo stadio di denoising considerati.

La struttura multirisoluzione combina informazione locale e globale: l'encoder riduce progressivamente la risoluzione delle feature map, mentre il decoder la ricostruisce fino alla dimensione originaria. Le skip connection collegano i livelli corrispondenti dei due percorsi e trasferiscono al decoder dettagli spaziali utili alla ricostruzione. L'output finale è una stima del rumore, con la stessa forma dell'immagine di ingresso.

La baseline incondizionata mantiene la stessa U-Net multirisoluzione e lo stesso processo di denoising, ma non utilizza né il text encoder né i moduli di cross-attention; in questo modo, il confronto isola l'effetto del conditioning testuale.



Schema 1. *Dalla caption al contesto testuale e percorso multirisoluzione della U-Net condizionata. Il contesto è calcolato una sola volta prima del sampling; la cross-attention opera nei livelli profondi e nel bottleneck.*

Per l'addestramento viene utilizzato l'ottimizzatore AdamW, con learning rate distinti per la U-Net e per l'encoder testuale. L'esecuzione su GPU impiega la precisione mista automatica, AMP, in formato float16 e il gradient clipping, che limita la norma dei gradienti. Le principali impostazioni sperimentali sono riportate nella **Tabella 1**.

Voce	Valore
Seed training / valutazione	2026 / 3107
Step / batch size	10.000 / 64
Learning rate U-Net / text encoder	2e-4 / 1e-4
Weight decay / gradient clipping	1e-4 / norma massima 1.0
Precision	AMP float16
Validation / checkpoint	ogni 500 / 1.000 step

Tabella 1. *Impostazioni principali del training conditional.*
La baseline usa lo stesso protocollo principale senza text encoder.

Durante l'addestramento vengono salvati checkpoint contenenti i pesi dei modelli, lo stato dell'ottimizzatore, il gradient scaler utilizzato da AMP, gli stati dei generatori casuali, lo storico delle misure e la migliore loss di validazione registrata: questi artefatti consentono di conservare lo stato dell'esperimento e supportano la ripresa dell'addestramento.

Validazione prima del training completo

Prima di avviare l'addestramento sull'intero training set, la pipeline è stata sottoposta a un esperimento di tiny overfit su un batch fisso e a una suite di test automatici. Il tiny overfit ha permesso di verificare che i componenti del modello potessero essere addestrati congiuntamente e che la loss diminuisse su un insieme ristretto e controllato di esempi.

In questo esperimento, l'evaluation loss è passata da un valore iniziale di 1.147447 a un valore finale ricalcolato di 0,011468, raggiungendo un minimo di 0,011207. La suite di verifica ha inoltre superato 87 test automatici, dedicati alla correttezza dei singoli componenti e alla compatibilità delle interfacce tra tokenizer, dataset, schedule di diffusione, Transformer, U-Net, sampler, trainer e sistema di checkpointing. Questi controlli forniscono una verifica preliminare della coerenza implementativa e della capacità di apprendimento della pipeline, senza sostituire la successiva valutazione della qualità generativa.

4) Risultati quantitativi

Dopo le verifiche preliminari, il modello condizionato e la baseline non condizionata sono stati valutati per confrontarne la capacità di denoising, la qualità delle immagini generate e il costo computazionale. La **Tabella 2** riassume la migliore loss di validazione, lo step del checkpoint selezionato, il Kernel Inception Distance (KID), il numero complessivo di parametri e il tempo medio di generazione per immagine.

Modello	Best validation loss	Best step	KID mean	KID std	Parametri	Sampling s/img
Conditional	0.004186	10.000	-0.005292	0.000788	12.004 M	11.260
Unconditional	0.006287	9.000	0.004312	0.001883	10.467 M	7.672

Tabella 2. *Confronto quantitativo tra il modello condizionato e la baseline non condizionata. Il KID è calcolato utilizzando 64 immagini reali del test ordinario e 64 immagini generate per ciascun modello.*

La qualità distribuzionale delle immagini generate è stata valutata mediante la Kernel Inception Distance (KID), calcolata con l'implementazione di TorchMetrics versione 1.9.0. Poiché la metrica è stata inizializzata con *normalize=True*, sia le immagini reali sia quelle generate sono state trasformate dall'intervallo [-1, 1] all'intervallo $[0, 1]$ prima del calcolo.

Il riferimento reale è costituito da 64 immagini dello split test ordinary, selezionate tramite indici equispaziati per coprire l'intero split senza limitarsi ai primi esempi disponibili. Per il modello condizionato, le corrispondenti caption sono state usate come input testuale; la baseline incondizionata ha invece generato immagini senza alcuna descrizione.

Entrambi i modelli hanno prodotto 64 campioni, utilizzando lo stesso seed di generazione, pari a 3107, così da rendere il confronto riproducibile e controllato. La KID è stata infine stimata su 100 subset casuali di 50 immagini ciascuno, riportando media e deviazione standard

L'estrattore Inception pre-addestrato viene impiegato esclusivamente per il calcolo del KID e non interviene né nell'addestramento né nel conditioning. Il valore medio leggermente negativo ottenuto dal modello condizionato è compatibile con la variabilità dello stimatore non distorto su un campione finito e non rappresenta una distanza teorica negativa. La deviazione standard riportata descrive la variabilità tra i subset della metrica, non quella tra addestramenti indipendenti. I risultati costituiscono pertanto un confronto interno a campione ridotto e non una dimostrazione conclusiva di superiorità generale.

La **Figura 1** mostra l'andamento delle loss di training e validazione, e individua i checkpoint selezionati: in entrambi i modelli si osserva una rapida riduzione iniziale dell'errore, seguita da una fase di miglioramento più graduale.

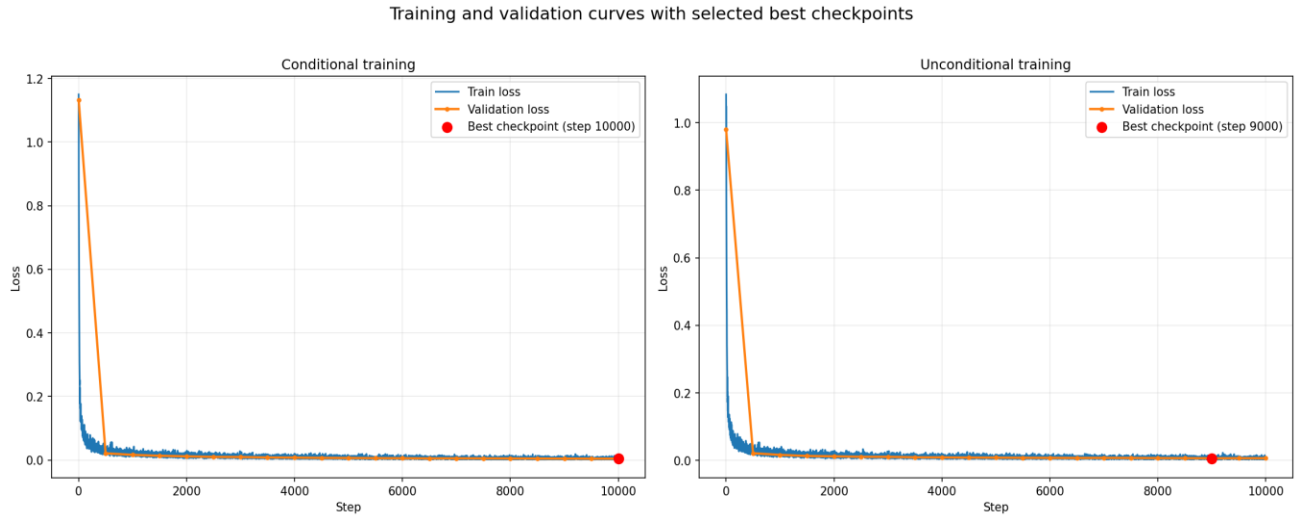


Figura 1. *Andamento delle loss di training e validazione per i due modelli. I punti evidenziati indicano i checkpoint con la migliore loss di validazione.*

Costo computazionale

Per affiancare alla valutazione generativa un'analisi dell'efficienza, è stato eseguito un benchmark di sampling su GPU Tesla T4. Le misure sono state raccolte con batch size pari a 1, escludendo un'esecuzione iniziale di warm-up e ripetendo il campionamento con cinque seed distinti. Entrambi i modelli utilizzano 1.000 step del processo inverso DDPM.

Nel modello condizionato, il contesto testuale viene calcolato prima del ciclo di sampling e riutilizzato a ogni timestep. Durante il denoising vengono inoltre eseguiti i moduli di cross-attention, che introducono un costo aggiuntivo rispetto alla baseline. Nel benchmark, il tempo medio di generazione è pari a $11{,}260 \pm 0{,}136$ secondi per immagine per il modello condizionato e a $7{,}672 \pm 0{,}063$ secondi per la baseline. La **Tabella 3** riporta questi valori insieme alla memoria occupata dai pesi e dai buffer e ai picchi di memoria CUDA osservati.

Configurazione	Pesi + buffer	Tempo medio / immagine	Picco CUDA allocato	Picco CUDA riservato
Conditional	45.81 MiB	11.260 ± 0.136 s	1753.79 MiB	1856.00 MiB
Unconditional	39.93 MiB	7.672 ± 0.063 s	1753.74 MiB	1856.00 MiB

Tabella 3. *Complessità, latenza e memoria durante il benchmark su GPU Tesla T4, con batch size 1, un'esecuzione di warm-up esclusa e cinque seed. I tempi sono riportati come media e deviazione standard delle cinque misurazioni.*

La memoria occupata dai pesi e dai buffer è pari a 45,81 MiB per la configurazione condizionata e a 39,93 MiB per la baseline. I picchi CUDA allocati e riservati descrivono invece la memoria del processo nel runtime di benchmark, che può includere altri oggetti ancora residenti sulla GPU. Non devono quindi essere interpretati come il fabbisogno esclusivo del singolo modello, né come la sola memoria occupata dai suoi pesi.

5) Valutazione qualitativa e OOD

Confronto controllato con la baseline

Alla valutazione quantitativa si affianca un'analisi qualitativa dei campioni generati, finalizzata a esaminare la plausibilità degli avatar e la loro coerenza con le descrizioni testuali. Il confronto considera quattro immagini reali del test ordinario e le rispettive caption. Per ciascuna configurazione viene utilizzata la stessa inizializzazione casuale: il modello condizionato riceve le descrizioni associate alle immagini reali, mentre la baseline genera senza alcun input testuale.

La **Figura 2** presenta, per ciascun esempio, l'immagine reale di riferimento, il campione condizionato e quello non condizionato. Nei campioni mostrati, il modello condizionato riproduce diverse caratteristiche riconoscibili dei riferimenti, pur con differenze in alcuni dettagli. La baseline produce invece avatar plausibili, ma non può essere guidata dagli attributi richiesti nelle caption; eventuali corrispondenze sono pertanto accidentali. Il confronto permette così di distinguere la capacità generale di generare avatar dal controllo esercitato attraverso il testo.

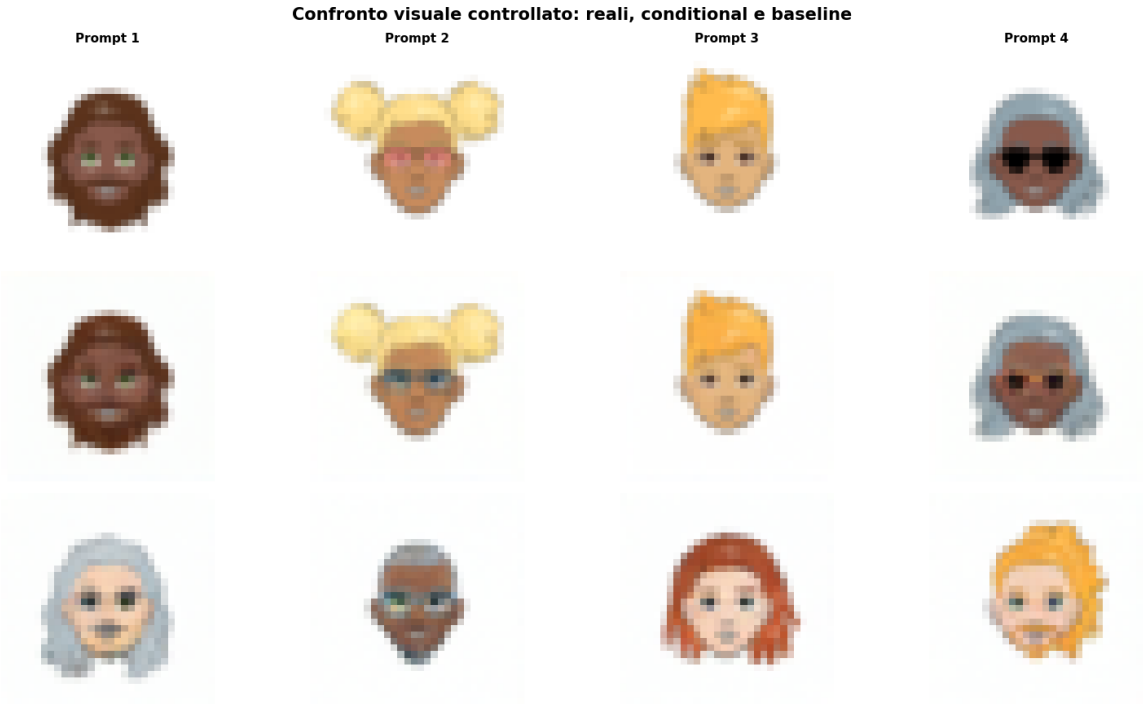


Figura 2. *Confronto qualitativo su quattro esempi del test ordinario. Dall'alto verso il basso: immagini reali di riferimento, generazioni condizionate dalle rispettive caption e generazioni della baseline non condizionata. I due modelli generativi utilizzano la stessa inizializzazione casuale.*

Campioni composizionali OOD

L'analisi viene successivamente estesa ai prompt dello split composizionale OOD, caratterizzati dalla presenza congiunta di face_shape = 3 e hair_color = 3. Come descritto nella definizione degli split, questa combinazione è assente dal training, mentre i singoli valori sono presenti in associazione ad altri attributi. La valutazione esplora quindi la capacità del modello di ricombinare caratteristiche già osservate separatamente durante l'addestramento.

La **Figura 3** mostra quattro campioni generati a partire da caption OOD dove gli avatar mantengono una struttura visivamente plausibile; tuttavia, la sola plausibilità non dimostra che entrambi gli attributi della combinazione trattenuta siano stati riprodotti correttamente. L'ispezione dei campioni costituisce pertanto un'evidenza qualitativa da affiancare alle misure di conditioning presentate nella sezione successiva, senza considerarla una verifica conclusiva della generalizzazione composizionale.

La risoluzione di 32×32 pixel limita inoltre la leggibilità di alcuni dettagli e può rendere meno immediata la distinzione tra varianti simili. Per questo motivo, l'interpretazione dei risultati tiene conto sia delle caratteristiche visibili nei campioni sia dei limiti degli strumenti utilizzati per valutarli.

Campioni conditional OOD

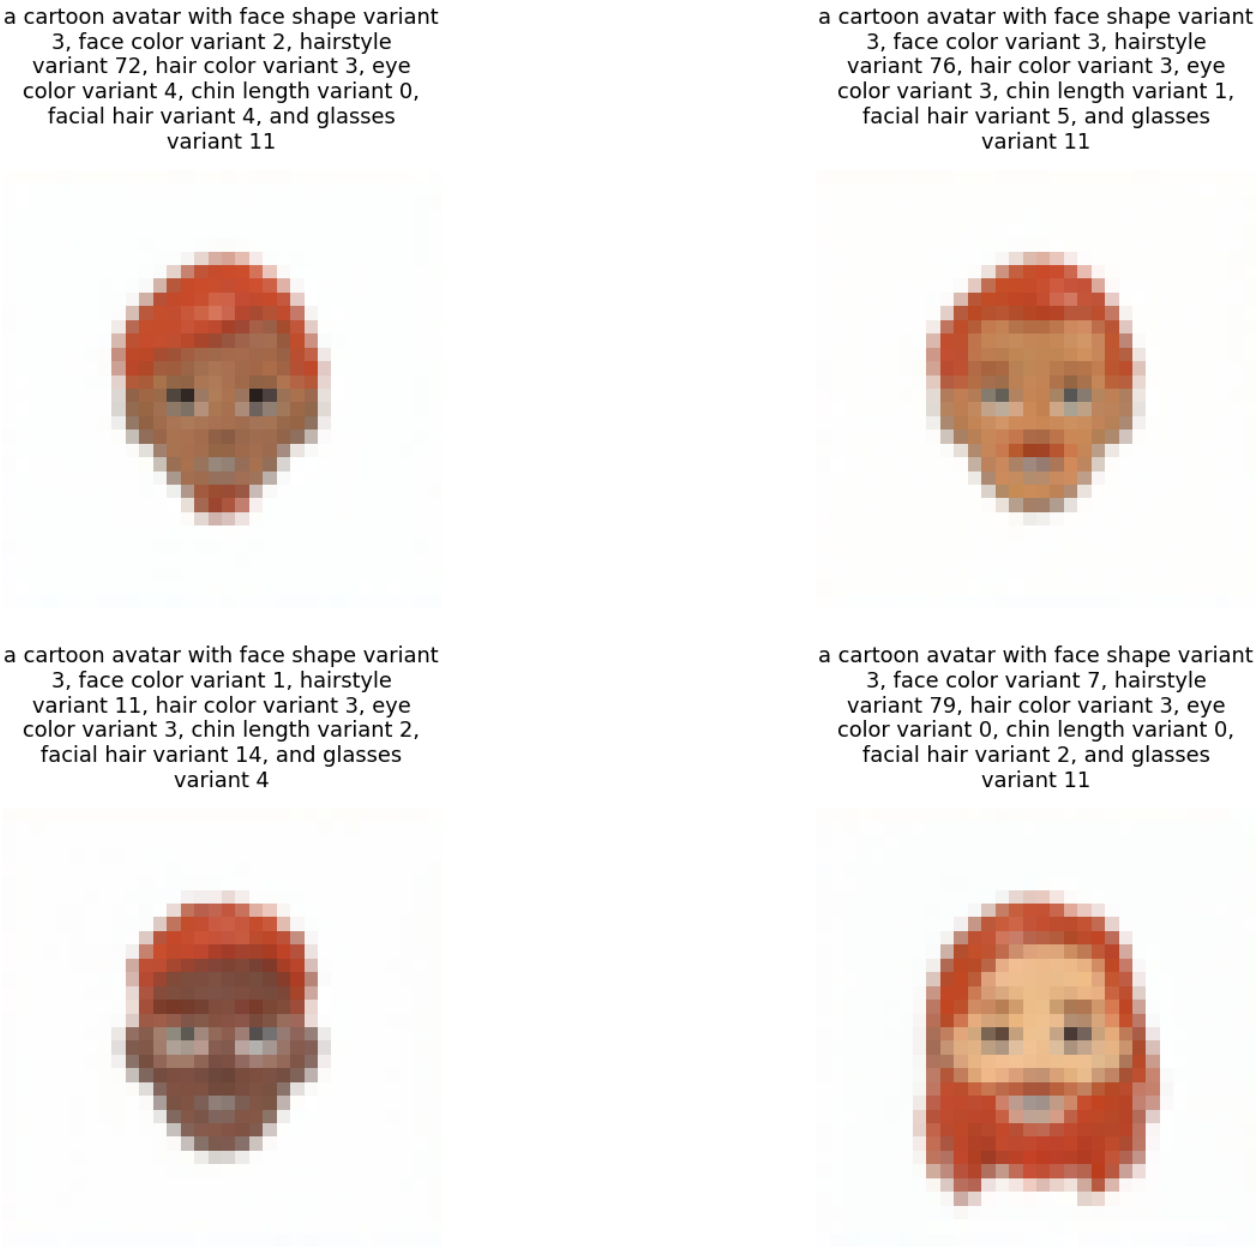


Figura 3. *Quattro campioni del modello condizionato generati a partire da caption dello split composizionale OOD, contenenti la combinazione face_shape = 3 e hair_color = 3.*

6) Conditioning e diversity

Proxy nearest-neighbor

Per approfondire la coerenza tra le immagini generate e gli attributi richiesti nei prompt, l'analisi qualitativa viene affiancata da una proxy basata sul nearest-neighbor. Per ciascuna immagine esaminata, il metodo individua il riferimento reale più vicino in termini di distanza euclidea nello spazio dei pixel e ne confronta gli attributi con quelli richiesti dalla caption. Il risultato costituisce quindi una misura indiretta di coerenza: gli attributi non vengono riconosciuti direttamente nell'immagine generata, ma sono assegnati sulla base del riferimento recuperato.

La valutazione utilizza un banco comune di 656 immagini reali, composto da 512 esempi del test ordinario e 144 del test OOD. Su questo stesso banco vengono applicati tre protocolli distinti. Nel primo, le immagini generate sono confrontate con tutti i riferimenti, compresa l'immagine reale da cui deriva il prompt. Nel secondo, tale riferimento viene escluso secondo un criterio leave-one-out. Il terzo applica lo stesso criterio alle immagini reali, utilizzate come query, per verificare il comportamento del valutatore indipendentemente dalla generazione.

La **Tabella 4** riporta, per ciascuno split e protocollo, il match medio sugli otto attributi, il match completo, la disponibilità nel banco della combinazione completa richiesta e il match congiunto di forma del viso e colore dei capelli.

Split	Query / protocollo	Match attributi	Match completo	Disponibilità combinazione completa	Match congiunto forma del viso e colore dei capelli
Ordinary	Generated, reference incluso	100,00%	100,00%	100,00%	100,00%
Ordinary	Generated, leave-one-out	32,23%	0,00%	0,00%	3,12%
Ordinary	Reale, leave-one-out	31,84%	0,00%	0,00%	4,69%
OOD	Generated, reference incluso	96,68%	93,75%	100,00%	98,44%
OOD	Generated, leave-one-out	43,36%	0,00%	0,00%	57,81%
OOD	Reale, leave-one-out	42,38%	0,00%	0,00%	56,25%

Tabella 4. *Valutazione della proxy di conditioning su 64 query ordinary e 64 query OOD per ciascun protocollo, utilizzando un banco comune di 656 immagini reali. L'ultima colonna misura il match congiunto di forma del viso e colore dei capelli; nello split OOD, la coppia richiesta coincide con la combinazione trattenuta face_shape = 3 e hair_color = 3.*

Con il riferimento associato al prompt incluso nel banco, il match completo raggiunge il 100% sulle query ordinary e il 93,75% sulle query OOD. Questi valori indicano che il nearest-neighbor recupera riferimenti con tutti gli attributi richiesti per la maggior parte delle generazioni considerate. Non devono tuttavia essere interpretati come un'accuratezza semantica indipendente, poiché dipendono dal confronto globale tra immagini e dalla composizione del banco di riferimento.

Il protocollo leave-one-out evidenzia un limite importante della misura: dopo l'esclusione dell'immagine associata al prompt, nessuna delle 128 query dispone di un altro riferimento con tutti gli otto attributi identici. Il match completo nullo è quindi imposto dalla copertura del banco e non dimostra che il generatore non sia in grado di rispettare integralmente la descrizione.

La calibrazione sulle immagini reali aiuta a interpretare anche i match parziali: nel protocollo leave-one-out, il match medio sugli attributi è pari al 32,23% per le generazioni ordinary e al 31,84% per le corrispondenti immagini reali; nello split OOD, i valori sono rispettivamente 43,36% e 42,38%. La vicinanza dei risultati mostra che i punteggi relativamente bassi non possono essere attribuiti direttamente a errori del generatore, poiché il medesimo valutatore produce valori analoghi anche sulle immagini reali.

Per la coppia composizionale OOD, che rimane disponibile nel banco per tutte le query anche dopo l'esclusione del riferimento associato, il match congiunto leave-one-out è pari al 57,81% sulle generazioni e al 56,25% sulle immagini reali. Questo confronto fornisce un elemento diagnostico sul comportamento della proxy, ma non costituisce da solo una verifica conclusiva della generalizzazione composizionale. I risultati vengono pertanto interpretati insieme ai campioni qualitativi, tenendo conto dei limiti del retrieval nello spazio dei pixel.

Diversity a prompt fisso

Accanto alla coerenza con la descrizione, viene analizzata la variabilità delle generazioni ottenute mantenendo invariato il prompt. L'obiettivo è verificare quanto cambino le immagini al variare dell'inizializzazione casuale, senza introdurre differenze nel contenuto testuale fornito al modello.

L'esperimento considera quattro prompt, due del test ordinario e due del test OOD. Per ciascun prompt vengono generati sei campioni con seed distinti, ottenendo 15 confronti a coppie. Le distanze sono calcolate esclusivamente tra immagini associate allo stesso prompt, per un totale di 60 coppie. La variabilità è misurata mediante RMSE e MAE pixel-wise sulle immagini nell'intervallo $[-1, 1]$; la **Tabella 5** riporta i risultati aggregati per split e sull'intero insieme valutato.

Split	Prompt	Campioni/prompt	Coppie intra-prompt	Pairwise RMSE	Pairwise MAE
Ordinary	2	6	30	0.041697	0.019750
OOD	2	6	30	0.027420	0.013157
Totale	4	6	60	0.034558	0.016454

Tabella 5. *Variabilità delle generazioni a prompt fisso, misurata mediante RMSE e MAE pixel-wise nell'intervallo [-1,1]. Ciascuno split comprende due prompt e 30 confronti intra-prompt; il totale comprende quattro prompt e 60 confronti.*

Nel campione analizzato, l'RMSE medio è pari a 0,041697 per i prompt ordinary e a 0,027420 per quelli OOD. Anche il MAE risulta inferiore nello split OOD. I valori indicano quindi una minore variabilità nei pixel per i due prompt OOD selezionati, senza consentire di estendere questa osservazione all'intera distribuzione o di concludere, da sola, che il modello presenti un collasso della diversità. La **Figura 4** affianca i campioni ottenuti con seed differenti, consentendo di esaminare visivamente le variazioni all'interno di ciascun gruppo. Nei casi mostrati, le differenze appaiono prevalentemente locali e contenute, mentre l'aspetto complessivo degli avatar rimane simile. Le distanze numeriche descrivono tuttavia variazioni nei pixel, non necessariamente variazioni semanticamente significative: per questo motivo vengono interpretate insieme alla griglia qualitativa.

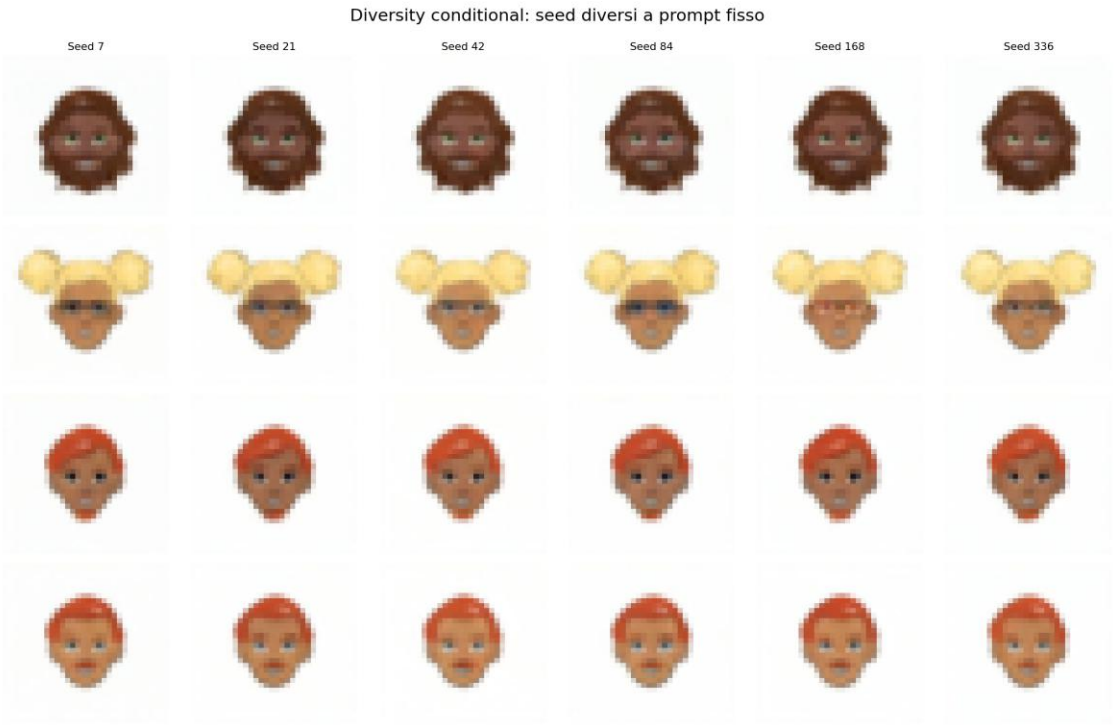


Figura 4. *Generazioni del modello condizionato per due prompt ordinary e due prompt OOD. Ogni riga corrisponde a un prompt fisso, mentre le sei colonne mostrano i campioni ottenuti con seed differenti.*

7) Discussione e limiti

I risultati delle sezioni precedenti offrono prospettive complementari sul comportamento del modello. La loss di validazione descrive la capacità di predire il rumore, il KID confronta le distribuzioni delle immagini reali e generate, mentre l'analisi qualitativa, la proxy di conditioning e le misure di diversity approfondiscono rispettivamente l'aspetto dei campioni, la loro coerenza con i prompt e la variabilità delle generazioni.

Nel protocollo sperimentale adottato, il modello condizionato ottiene una loss di validazione e un KID medio inferiori rispetto alla baseline non condizionata. I campioni mostrati evidenziano inoltre la possibilità di guidare diverse caratteristiche degli avatar attraverso descrizioni testuali strutturate. Queste osservazioni sono favorevoli alla configurazione condizionata, ma non dimostrano una superiorità generale: il confronto riguarda un singolo addestramento per configurazione, il KID è stimato su un campione ridotto e i due modelli non hanno lo stesso numero di parametri.

Il beneficio del conditioning comporta anche un costo computazionale aggiuntivo. Entrambi i modelli eseguono 1.000 step del processo inverso DDPM, ma la configurazione condizionata richiede la codifica iniziale del testo e l'esecuzione dei moduli di cross-attention durante il denoising. La risoluzione di 32×32 pixel consente di contenere il costo dell'esperimento, limitando tuttavia la quantità di dettaglio rappresentabile e contribuendo potenzialmente alla presenza di contorni poco definiti.

La valutazione del conditioning richiede particolare cautela. Il nearest-neighbor nello spazio dei pixel non riconosce direttamente gli attributi presenti nelle immagini, ma assegna quelli del riferimento reale più vicino. Il confronto tra riferimento incluso, leave-one-out e calibrazione sulle immagini reali permette di distinguere alcuni limiti del valutatore da possibili errori del generatore. In particolare, l'assenza di riferimenti con la combinazione completa dopo l'esclusione dell'immagine associata al prompt rende inevitabile un match completo nullo, anche sulle query reali.

La generalizzazione composizionale viene quindi analizzata attraverso evidenze indirette e campioni qualitativi, senza considerarla definitivamente dimostrata da una singola misura. Analogamente, la diversity osservata su quattro prompt descrive soltanto il campione selezionato e non consente di caratterizzare l'intera distribuzione delle generazioni. Anche le misure di memoria devono essere interpretate nel loro contesto: i picchi CUDA riportati riguardano il processo nel runtime di benchmark e non isolano il fabbisogno del singolo modello.

Miglioramenti futuri

Le possibili estensioni del lavoro riguardano soprattutto il consolidamento della valutazione e lo studio del rapporto tra qualità, controllo ed efficienza. Si tratta di sviluppi da affrontare in esperimenti separati, mantenendo distinguibili i risultati attuali da quelli ottenuti con nuove configurazioni.

Una prima direzione consiste nell'ampliare il campione utilizzato per il KID e ripetere la generazione con più seed, così da analizzare la stabilità del confronto su insiemi di immagini differenti. La valutazione semantica potrebbe inoltre essere approfondita mediante un classificatore di attributi addestrato separatamente sui dati reali di training e validato prima dell'impiego sulle immagini

generate. Questo consentirebbe di affiancare alla proxy di retrieval uno strumento che stimi direttamente gli attributi visibili.

Sul piano dell'efficienza, sarebbe utile confrontare il sampler DDPM con procedure di campionamento accelerate, misurando l'effetto della riduzione dei passi sulla qualità delle immagini e sulla coerenza con il prompt. Un aumento della risoluzione potrebbe invece permettere di rappresentare dettagli più fini, ma richiederebbe una nuova valutazione dei costi di addestramento, sampling e memoria.

Infine, un'analisi estesa a un maggior numero di prompt ordinary e OOD permetterebbe di studiare in modo più sistematico il rapporto tra fedeltà alla descrizione e variabilità delle generazioni, distinguendo le differenze nei pixel dalle variazioni semanticamente significative.

8) Conclusioni

Il progetto ha portato alla realizzazione di una pipeline completa di diffusione condizionata dal testo, con denoiser ed encoder testuale addestrati da zero. Il sistema comprende la preparazione e la verifica dei dati, uno split composizionale OOD, la costruzione delle caption e del tokenizer, un Transformer testuale, una U-Net multirisoluzione con cross-attention e un processo DDPM nello spazio dei pixel. Il confronto con una baseline non condizionata è accompagnato da una valutazione quantitativa, qualitativa e computazionale.

Nel protocollo interno, il modello condizionato raggiunge risultati migliori della baseline nella predizione del rumore e nel KID medio. I campioni esaminati mostrano inoltre una coerenza visiva con diverse caratteristiche richieste dai prompt, mentre gli esperimenti OOD consentono di esplorare la generazione di una combinazione esclusa dall'addestramento. Le evidenze raccolte sono incoraggianti, ma i limiti del campione e degli strumenti di valutazione non consentono di formulare conclusioni definitive sulla generalizzazione composizionale.

Il contributo del lavoro risiede quindi sia nell'implementazione verificabile del sistema sia nell'analisi critica dei suoi risultati. La distinzione tra prestazioni del generatore e limiti del valutatore permette di descrivere con maggiore precisione ciò che gli esperimenti mostrano e di individuare le verifiche necessarie per consolidare le conclusioni. Nel complesso, il progetto mostra che anche un modello di diffusione compatto, interamente addestrato da zero, può costituire una base sperimentale solida per studiare il text conditioning e la generalizzazione composizionale, purché i risultati siano interpretati con protocolli di valutazione adeguati e verifiche più estese.

[1]: https://huggingface.co/datasets/cgarciae/cartoonset/resolve/1.0.0/data/cartoonset10k.tgz?download=true